



Università degli Studi di Milano-Bicocca

Corso: Large Scale Data Management

Documentazione Progetto

Data Warehouse

Simone Madaghiele – Matricola: 918569

Nicolò Nicholas Zagami – Matricola: 829888

Gennaio 2026

Indice

1	Obiettivo del Progetto	1
2	Dataset Iniziale	2
2.1	Games	2
2.2	Reviews	2
2.3	Integrazione dei Dataset	3
3	Dimensional Fact Model (DFM)	4
3.1	Fatto	4
3.2	Misure	4
3.3	Dimensioni	4
3.3.1	Dimensione Date	4
3.3.2	Dimensione User	4
3.3.3	Dimensione Game	5
3.4	Considerazioni Progettuali	5
4	Progettazione Logica	7
4.1	Tabella dei Fatti: Review	7
4.2	Dimensioni Principali	7
4.2.1	Date	7
4.2.2	User	7
4.2.3	Game	7
4.3	Gestione di Attributi Multi-valued tramite Bridge Tables	7
4.4	Considerazioni Finali	8
5	Architettura e Stack Tecnologico	9
5.1	Schemi locali	10
5.2	ETL	10
5.2.1	Extract	10
5.2.2	Transform	11
5.2.3	Load	11
5.3	Meccanismo di retry e "edge cases"	12
6	Dashboard Analitiche	13
6.1	Games	14
6.1.1	Overview	14
6.1.2	Analisi sui prezzi	14
6.1.3	Struttura del mercato	17
6.1.4	Explorer	19
6.2	Reviews	21
6.2.1	Overview	21
6.2.2	distribuzione del rating	21
6.2.3	Concentrazione delle recensioni	22
6.2.4	Engagement, testo e sentiment	23
7	Conclusioni	25

1 Obiettivo del Progetto

L'obiettivo del progetto è la realizzazione di un sistema di analisi basato su un *Data Warehouse* a partire da un dataset di grandi dimensioni relativo ai videogiochi pubblicati sulla piattaforma Steam e alle recensioni degli utenti.

Il dataset di partenza, ottenuto da Kaggle, contiene informazioni eterogenee sui giochi (ad esempio identificativo, nome, genere, sviluppatore, data di rilascio, prezzo) e un volume molto elevato di recensioni utente, caratterizzate da attributi temporali, valutazioni esplicite, testo libero e segnali di engagement (come voti di utilità). La natura del dataset rende inefficiente un approccio puramente transazionale e motiva l'adozione di un modello multidimensionale orientato all'analisi.

Il progetto mira quindi a:

- progettare un *Dimensional Fact Model* (DFM) adeguato alla rappresentazione dei fenomeni di interesse, con particolare attenzione all'analisi delle recensioni;
- costruire uno schema logico di Data Warehouse (star schema) a supporto di query analitiche;
- definire e implementare una pipeline ETL scalabile per l'ingestione, la pulizia, la deduplicazione e la trasformazione dei dati;
- consentire l'analisi esplorativa e descrittiva del dominio attraverso metriche, aggregazioni e visualizzazioni.

Le analisi effettuate permettono di rispondere a domande di business quali: l'evoluzione temporale del volume di recensioni, la distribuzione dei rating per genere o sviluppatore, il grado di concentrazione delle recensioni su un sottoinsieme di giochi, e il livello di engagement degli utenti in relazione alla lunghezza o al sentiment del testo.

2 Dataset Iniziale

Il progetto utilizza come sorgente dati: *Steam Games Dataset*, ottenuto dalla piattaforma Kaggle al seguente link: <https://www.kaggle.com/datasets/fronkongames/steam-games-dataset>

Il dataset è organizzato in due cartelle principali, **games** e **reviews**, che descrivono rispettivamente le informazioni relative ai videogiochi pubblicati su Steam e le recensioni lasciate dagli utenti.

La separazione logica tra i due domini, unita all'elevato volume dei dati, ha reso necessario un approccio di gestione e integrazione scalabile, basato su database eterogenei e su una pipeline ETL dedicata.

2.1 Games

La cartella **games** contiene più file relativi ai videogiochi disponibili sulla piattaforma Steam. Tutti i file presenti sono stati integrati in un unico dataset, successivamente caricato in un database MongoDB, scelto per la sua flessibilità nella gestione di dati semi-strutturati e per facilitare le operazioni di pulizia e selezione degli attributi.

Le operazioni di integrazione, analisi preliminare e pulizia dei dati sono state realizzate attraverso una serie di notebook, utilizzati per esplorare la struttura del dataset, valutarne la qualità e supportare le decisioni progettuali relative alla selezione degli attributi. Tali notebook hanno consentito di verificare la presenza di ridondanze, valori nulli e campi non informativi, guidando in modo sistematico il processo di preprocessing.

Durante questa fase sono state eliminate diverse colonne ritenute non rilevanti ai fini del progetto e dell'analisi multidimensionale. In particolare, sono stati rimossi:

- i campi relativi ai requisiti hardware minimi e raccomandati, `minimum_pc_requirements` e `recommended_pc_requirements`;
- il campo `controller_support`, caratterizzato da una percentuale elevata di valori nulli;
- campi descrittivi estesi e ridondanti, come `detailed_description` e `about_the_game`, che presentano contenuti sostanzialmente sovrapposti;
- attributi puramente informativi o facilmente derivabili, tra cui `header_image`, `windows_support`, `mac_support`, `linux_support`, `coming_soon`, `recommendations` e `dlc`;
- metadati tecnici e di scraping, quali `scrape_date`, `filename`, `source_path`, `file_origin`, `rn` e `rn_1`.

Il risultato è un dataset contenente esclusivamente gli attributi necessari alla descrizione dimensionale dei giochi (identificativo, nome, genere, sviluppatore, editore, data di rilascio, prezzo), utilizzabile come base per la dimensione **Game** del Data Warehouse.

2.2 Reviews

La cartella **reviews** contiene un volume molto elevato di recensioni utente, dell'ordine di decine di milioni di record. Per ridurre la complessità e garantire coerenza nelle analisi testuali, sono state considerate esclusivamente le recensioni in lingua inglese, che rappresentano oltre 21 milioni di osservazioni.

Data la natura massiva e append-only delle recensioni, queste sono state inizialmente caricate in un database Cassandra, scelto per la sua capacità di gestire grandi volumi di dati distribuiti e per l'elevata efficienza nelle operazioni di lettura sequenziale.

Anche in questo caso è stata effettuata una fase di selezione degli attributi, eliminando campi non utili alle analisi di progetto, tra cui:

- informazioni relative all'attività di gioco recente e al profilo di possesso, come `playtime_last_two_weeks` e `num_games_owned`;
- timestamp tecnici di creazione e aggiornamento delle recensioni, quali `timestamp`, `timestamp_created` e `timestamp_updated`;
- metriche derivate o poco interpretabili ai fini dell'analisi, come `weighted_vote_score`;
- campi relativi a interazioni secondarie e metadati di contesto, tra cui `comment_count`, `steam_purchase`, `scrape_date` e `primarily_steam_deck` / `primarily_steam_deck`.

Il dataset risultante mantiene le informazioni fondamentali per l'analisi delle recensioni: valutazione espressa, testo della recensione, voti di utilità, lingua e riferimento al gioco recensito.

2.3 Integrazione dei Dataset

I due dataset sono logicamente collegati tramite l'identificativo del gioco (`appid`), che definisce una relazione uno-a-molti tra giochi e recensioni. A valle della pipeline ETL, i dati provenienti da MongoDB e Cassandra sono stati integrati e caricati all'interno del Data Warehouse, costituendo la base per la modellazione multidimensionale e per le successive analisi.

3 Dimensional Fact Model (DFM)

Il fenomeno analizzato nel progetto riguarda il comportamento degli utenti di Steam nell'interazione con i videogiochi, osservato attraverso le recensioni pubblicate sulla piattaforma. Per rappresentare tale fenomeno è stato progettato un *Dimensional Fact Model* (DFM), che consente di supportare analisi multidimensionali lungo assi temporali, di contenuto e di profilo dell'utente.

Il modello è centrato sull'evento di pubblicazione di una recensione e integra informazioni relative al gioco recensito, all'utente autore della recensione e al momento temporale in cui l'evento si verifica.

3.1 Fatto

Il fatto principale del modello è **Review**, che rappresenta una singola recensione lasciata da un utente per un determinato gioco in una specifica data.

Ogni istanza del fatto corrisponde quindi a un evento atomico, identificato dalla combinazione di gioco, utente e tempo. Il fatto è associato a diverse misure quantitative, utili per analisi di engagement, qualità e contenuto delle recensioni.

3.2 Misure

Le misure associate al fatto **Review** includono:

- **votes_up**: numero di utenti che hanno valutato positivamente la recensione;
- **votes_funny**: numero di utenti che hanno valutato la recensione come divertente;
- **review_word_count**: numero di parole del testo della recensione;
- **sentiment**: valore derivato dall'analisi del sentiment del testo della recensione.

Queste misure permettono di analizzare sia la popolarità delle recensioni sia il livello di coinvolgimento degli utenti e la natura del contenuto prodotto.

3.3 Dimensioni

Il fatto **Review** è descritto attraverso le seguenti dimensioni:

3.3.1 Dimensione Date

La dimensione **Date** rappresenta il momento temporale in cui la recensione viene pubblicata ed è modellata tramite una gerarchia classica:

$$Year \rightarrow Month \rightarrow Day$$

Questa dimensione consente analisi temporali a diversi livelli di granularità, come trend annuali, mensili o giornalieri delle recensioni.

3.3.2 Dimensione User

La dimensione **User** descrive il profilo dell'utente che ha scritto la recensione. Include attributi legati all'attività complessiva dell'utente sulla piattaforma, tra cui:

- tempo di gioco totale (*playtime forever*);
- tempo di gioco al momento della recensione (*playtime at review*);
- numero totale di recensioni scritte;

- numero di giochi posseduti;
- lingua dell'utente;
- data dell'ultima attività (*last played*).

Tali attributi permettono di segmentare le recensioni in base al livello di esperienza e coinvolgimento dell'utente.

3.3.3 Dimensione Game

La dimensione **Game** descrive le caratteristiche del videogioco recensito. Tra gli attributi principali figurano:

- genere e categoria del gioco;
- prezzo;
- editore (*publisher*);
- data di rilascio;
- età minima richiesta;
- indicazione di *free-to-play*;
- punteggio medio delle recensioni.

Questa dimensione consente analisi comparative tra giochi, generi o publisher e supporta lo studio delle dinamiche di mercato e di gradimento dei contenuti.

3.4 Considerazioni Progettuali

Il DFM è stato progettato privilegiando una struttura chiara e facilmente estendibile, in grado di supportare sia analisi descrittive sia analisi più avanzate sul contenuto testuale delle recensioni. La scelta di mantenere il testo della recensione come attributo descrittivo, e non come misura, consente di integrare tecniche di analisi del linguaggio naturale senza compromettere la semplicità del modello multidimensionale.




Figura 1: Dimensional Fact Model.

4 Progettazione Logica

A partire dal DFM presentato nella sezione precedente, è stato progettato lo schema logico del Data Warehouse adottando un approccio *star schema*. La scelta è motivata dalla necessità di supportare query OLAP e aggregazioni su grandi volumi di recensioni, mantenendo al contempo un modello semplice da interrogare e facilmente estendibile.

Lo schema è centrato sulla tabella dei fatti **Review**, collegata alle dimensioni principali **Date**, **User** e **Game**. Inoltre, alcuni attributi del gioco (ad esempio generi, categorie e publisher) presentano una natura *multi-valued* (un gioco può appartenere a più generi/categorie o avere più publisher). Per modellare correttamente tali relazioni molti-a-molti, sono state introdotte tabelle ponte (*bridge tables*) che collegano la dimensione **Game** a dimensioni normalizzate (**Genre**, **Category**, **Publisher**).

4.1 Tabella dei Fatti: Review

La tabella dei fatti **Review** rappresenta l'evento atomico della pubblicazione di una recensione. Essa contiene chiavi esterne verso le dimensioni e un insieme di misure utili a descrivere engagement e contenuto.

- **Chiavi (FK):** ID_date, ID_user, ID_game
- **Misure:** votes_up, votes_funny, review_word_count, sentiment
- **Attributo descrittivo:** review_text (mantenuto per analisi testuali e derivazione di metriche come word count e sentiment)

La granularità del fatto è *una riga per recensione*, identificabile tramite un identificativo tecnico (ID_rec) e la combinazione delle chiavi dimensionali (gioco, utente, data).

4.2 Dimensioni Principali

4.2.1 Date

La dimensione **Date** include gli attributi **year**, **month** e **day**, e consente analisi temporali a diversi livelli di aggregazione (trend mensili/annuali, stagionalità, ecc.).

4.2.2 User

La dimensione **User** descrive il profilo dell'autore della recensione attraverso attributi di attività e contesto, tra cui: **playtime_at_review**, **playtime_forever**, **review_number**, **language**, **owned_games** e **last_played**. Tali attributi permettono segmentazioni per esperienza e coinvolgimento.

4.2.3 Game

La dimensione **Game** contiene le caratteristiche del gioco recensito: **name**, **price**, **review_score**, **required_age**, **free_to_play** e **release_date**. Questa dimensione rappresenta l'asse principale per confronti tra prodotti e per analisi per fascia di prezzo, periodo di rilascio e qualità percepita.

4.3 Gestione di Attributi Multi-valued tramite Bridge Tables

Nel dominio Steam, attributi come generi, categorie e publisher possono assumere più valori per lo stesso gioco. Per evitare duplicazioni della dimensione **Game** e mantenere lo schema coerente, tali attributi sono stati modellati tramite dimensioni dedicate (**Genre**, **Category**, **Publisher**) e tabelle ponte:

- **Genre__Game**(ID_game, ID_genre)
- **Category__Game**(ID_game, ID_category)
- **Publisher__Game**(ID_game, ID_publisher)

4.4 Considerazioni Finali

Lo star schema progettato consente di rappresentare in modo strutturato il fenomeno analizzato, con la tabella dei fatti **Review** come elemento centrale e le dimensioni associate a supporto delle analisi multidimensionali. La struttura adottata permette di eseguire operazioni di aggregazione e analisi lungo le principali dimensioni del modello.

L'introduzione di tabelle ponte per la gestione di attributi multi-valued consente di modellare correttamente le relazioni molti-a-molti presenti nel dominio dei videogiochi, mantenendo la coerenza del modello e facilitando l'esecuzione di query analitiche sul Data Warehouse.




Figura 2: Star Schema del Data Warehouse.

5 Architettura e Stack Tecnologico




Figura 3: Overview architettura

Shortlist tecnologie utilizzate:

- **Schemi locali:** MongoDB, Cassandra
- **Streaming dati:** Kafka
- **GUI per i messaggi AKHQ**
- **Storage system:** MinIo, uno strumento che replica i bucket S3 (AWS)
- **Trasformazione dei dati:** Polars
- **Data warehouse:** Postgres
- **Orchestratore ETL:** Prefect
- **Dashboard e Analytics:** Streamlit

5.1 Schemi locali

Per ottenere i dati negli schemi locali dei due database (**MongoDB** e **Cassandra**) è stato utilizzato **Kafka**, il quale fornisce una soluzione scalabile di streaming di dati attraverso l'utilizzo di producer e consumer. Prima del salvataggio, ai dati viene applicato un nuovo campo chiamato *"updated_at"*, il cui scopo è quello di fornire un riferimento temporale per creare le estrazioni giornaliere.

5.2 ETL

Il processo è stato orchestrato mediante l'utilizzo del framework **Prefect**:

- **Deployment dei flussi:** Prefect permette di deployare flussi con una cadenza schedulata (ad esempio: giornaliera) mediante l'utilizzo delle **cron expression**
- **Chiarezza:** Prefect permette una scrittura compatta e chiara dei flussi e dei task che verranno eseguiti, i quali saranno poi visualizzati nella dashboard messa a disposizione dal framework
- **Dashboard Prefect:** All'interno della dashboard è possibile verificare l'esito di un flusso e il tempo di esecuzione; questo permette di analizzare la qualità dei flussi sviluppati o di verificarne il corretto funzionamento

La fase di ETL è stata suddivisa in tre **sottoflussi**: un flusso per ogni operazione (*Extract, Transform, Load*).

5.2.1 Extract

I dati vengono estratti dai database locali di **Mongo** e **Cassandra** mediante un parametro chiamato *"extraction_date"*: la data viene definita attraverso la cron expression nel deployment della pipeline su *Prefect*; nel nostro caso si tratta di un'estrazione giornaliera.

I dati estratti vengono successivamente salvati in un file **Parquet** con la seguente nomenclatura: *extraction_date_GAMES* o *REVIEWS_run_id* e caricati su un bucket **MinIO** per essere elaborati dal flusso successivo.

5.2.2 Transform

Una volta recuperati i due file **Parquet** (uno per games e uno per reviews) da MinIO (ingested-files), questi vengono trasformati in dataframe Polars e vengono applicate alcune trasformazioni e processi di pulizia:

- **Unix timestamp:** All'interno del dataframe di review è presente un campo chiamato *"last_played"*, il quale utilizza un unix timestamp al posto di una data più comunemente interpretabile; abbiamo quindi deciso di convertirlo in datetime
- **Filtraggio dei games:** Durante un'analisi del dataset è stato scoperto che per uno stesso videogioco possono esserci più identificativi (*appid*); di conseguenza abbiamo scelto di filtrare i giochi selezionando la prima occorrenza per mantenere l'effettiva unicità una volta salvato il dato nel data warehouse e non produrre dashboard incongruenti
- **Sotto-dataframe:** Al fine di ottenere un processamento più pulito ed efficiente nelle varie fasi di salvataggio dei dati nel DWH, abbiamo previsto la creazione di alcuni sotto-dataframe a partire dai due principali:
 - *Date:* ogni data contenuta nel dataframe di review è stata estratta e riportata in un nuovo dataframe che verrà utilizzato per effettuare il salvataggio; inoltre viene aggiunto un campo *"date_id"* all'interno del dataframe di review, il quale verrà utilizzato per associarsi alla tabella Date
 - *Game e colonne multi-valore:* Per ogni game presente nel dataframe ci sono tre colonne che presentano una lista di valori: *"Genre"*, *"Category"* e *"Publisher"*. Ognuna di queste contiene uno o più valori: di conseguenza esplodiamo la lista in tante righe game-valore per tutti i valori associati; vengono quindi creati 3 dataframe diversi: **game-genre**, **game-categories**, **game-publishers**

Alla fine di tutte le trasformazioni i dataframe verranno caricati sotto forma di file **Parquet** su MinIO nel path *transformed-files*.

5.2.3 Load

Infine vengono prelevati tutti i file **Parquet** generati all'interno del bucket su MinIO e inseriti in un dataframe **Polars**:

- Un dataframe per i *games*
- Un dataframe per le *reviews*
- Un dataframe per le *dates*
- Un dataframe per ogni **bridge table**: *genre/category/publisher-games*

A partire dal dataframe **games** vengono aggiornate le tabelle **Genre**, **Category** e **Publisher** composte da un progressivo e dal relativo valore. Successivamente vengono effettuate le operazioni di salvataggio sul data warehouse sfruttando un inserimento in batch; la *batch_size* è configurabile e viene utilizzata per diverse ragioni:

- **Efficienza delle operazioni:** raggruppare molteplici operazioni in una singola transazione riduce drasticamente l'overhead delle connessioni al database; al posto di aprire N connessioni ne viene aperta solo una per processarne N insieme
- **Ottimizzazione delle risorse:** miglior utilizzo di cache e memoria, non si corre il rischio di saturare la memoria e si minimizzano i lock sul database

- **Consistenza dei dati:** utilizzando un processamento in batch è possibile sfruttare il caricamento atomico dei dati; questo garantisce che, in caso di errore, venga eseguito un rollback senza ritrovarsi con dati parziali o inconsistenti

Le operazioni di salvataggio vengono effettuate con il seguente ordine per rispettare l'integrità dei dati e le relazioni fra le entità:

- Salvataggio dei *games*
- Salvataggio delle *bridge tables*
- Salvataggio *users*
- Salvataggio *dates*
- salvataggio *reviews*

5.3 Meccanismo di retry e "edge cases"

Ogni flusso sfrutta le proprietà del framework **Prefect** per effettuare il retry del singolo flusso, il retry viene effettuato per un massimo di tre volte e con un delay di qualche secondo tra un tentativo e l'altro. Inoltre sono stati gestiti anche altri casi spinosi all'interno dell'intero processamento come:

- **Review non coerenti con i games:** Nel caso si presentassero delle review che fanno riferimento a game con id sconosciuti o game non ancora inseriti nel sistema esse verranno salvate in una tabella **Failed_Review**, la quale verrà utilizzata per eventuali riprocessamenti fino ad un massimo di **dieci tentativi**; ad ogni nuovo tentativo fallito verrà applicato un backoff esponenziale per la data di riprocessamento: 1, 2, 4, 8, 16, 32 giorni ecc..
- **Retry che hanno esaurito il numero massimo:** ad ogni processamento viene salvata la data corrente di estrazione con lo stato interno (*pending, running, failed, completed*) all'interno della tabella **Pipeline_Run**. Lo stato inizia il suo ciclo in stato pending, continua in running e conclude in uno tra failed o completed; nel caso in cui lo stato fosse failed la data corrente viene riprovata prima della prossima data nell'esecuzione successiva.

6 Dashboard Analitiche



Figura 4: Main page della dashboard

A valle della progettazione del Data Warehouse e della pipeline ETL, è stato sviluppato un sistema di dashboard interattive con l'obiettivo di consentire l'esplorazione e l'**analisi dei dati** in modo intuitivo ed efficiente. Le dashboard rappresentano il livello finale del sistema informativo e permettono di valorizzare il modello multidimensionale progettato, traducendo i dati in insight analitici.

Le dashboard sono state realizzate utilizzando *Streamlit* e interrogano direttamente il Data Warehouse tramite query analitiche.

Il sistema è organizzato in due principali viste analitiche: **Games Overview** e **Reviews Overview**, ciascuna focalizzata su un diverso aspetto del dominio.

6.1 Games

6.1.1 Overview

La dashboard **Games Overview** è dedicata all'analisi delle caratteristiche dei videogiochi presenti nel dataset e alla loro distribuzione rispetto a vari attributi dimensionali. L'obiettivo principale è fornire una visione aggregata del catalogo Steam, evidenziando pattern di mercato e differenze tra categorie di giochi.



Figura 5: Dashboard game - overview

6.1.2 Analisi sui prezzi

L'analisi dei prezzi permette di comprendere la strategia di Steam, evidenziando come si distribuisce il catalogo tra **free to play** e titoli a **pagamento**, e verificando se esiste una correlazione tra il prezzo di un gioco e la sua qualità percepita dagli utenti; un'informazione utile sia per i consumatori che vogliono capire se "pagare di più" significhi effettivamente "giocare meglio", sia per gli sviluppatori che devono posizionare il proprio prodotto.

- **Distribuzione prezzi:** Questo istogramma permette di identificare rapidamente le fasce di prezzo più popolate nel mercato, rivelando pattern di concentrazione e segmentazione. L'utilizzo di fasce predefinite (low/mid/high/premium) consente di standardizzare l'analisi e rendere comparabili dataset diversi, fornendo una visione d'insieme immediata della strategia di pricing del settore.
- **Rating medio per fascia prezzo:** Questo grafico approfondisce l'analisi precedente disaggregando i giochi a pagamento in tre segmenti specifici (High: 15-38.99€, Low: <5€, Mid: 5-14.99€). La visualizzazione permette di verificare se all'aumentare del prezzo corrisponda un incremento proporzionale della qualità percepita, testando l'ipotesi che fasce premium offrano esperienze superiori. L'uniformità dei rating tra le diverse fasce evidenzia come il prezzo non sia un predittore affidabile della qualità nel mercato videoludico.

- **Confronto free vs paid:** Il grafico a barre affiancate è ideale per confrontare metriche aggregate tra due categorie distinte. Visualizzare il rating medio per modello di business permette di testare empiricamente se esiste una correlazione tra prezzo e qualità percepita, rispondendo a una domanda chiave per consumatori e sviluppatori: "pagare garantisce maggiore qualità?"
- **Correlazione prezzo-qualità:** Questo scatter plot ci permette di analizzare se esiste una relazione tra quanto costa un gioco e quanto viene effettivamente apprezzato dal pubblico pagante attraverso l'utilizzo del review score.




Figura 6: Dashboard game - sottosezione prezzi

6.1.3 Struttura del mercato

- **Struttura del mercato (catalogo):** Questi istogrammi visualizzano la distribuzione quantitativa dei titoli per genere e publisher, permettendo di identificare quali segmenti dominano il mercato in termini di offerta. La vista Top consente di focalizzarsi sulle categorie più rilevanti evitando rumore da dati marginali. Confrontando questi due grafici si comprende sia la composizione merceologica del catalogo (quali tipologie di giochi sono disponibili) sia la struttura competitiva del settore (concentrazione vs frammentazione tra editori), rivelando se il mercato è dominato da pochi grandi publisher o frammentato tra molti piccoli operatori.
- **Genere vs Engagement (recensioni per gioco + rating):** Questi grafici affiancati misurano due dimensioni complementari della relazione tra utenti e contenuti. Il numero di recensioni per gioco rivela l'engagement effettivo (quanta attenzione riceve mediamente ciascun titolo), mentre il rating medio esprime la qualità percepita. Incrociando queste metriche si distingue tra generi con alto volume ma basso coinvolgimento individuale (cataloghi saturi) e generi di nicchia con forte engagement della community (mercati concentrati su pochi titoli di qualità). Questa analisi permette di identificare opportunità di mercato e generi a rischio saturazione.
- **Publisher: qualità vs quantità (scatter):** Lo scatter plot è ideale per identificare pattern bivariati nella strategia dei publisher. Ogni punto rappresenta un publisher (con almeno 2 giochi), permettendo di classificarli in archetipi strategici: specialisti di qualità (pochi giochi, alto rating), generalisti di successo (molti giochi, alto rating), mass market (molti giochi, rating variabile), e boutique inconsistenti (pochi giochi, rating medio-basso). Questa visualizzazione rivela la relazione tra produttività editoriale e qualità media del catalogo.
- **Top publisher per rating (min giochi):** Il filtro sul numero minimo di giochi (impostabile interattivamente) elimina il bias dei publisher con cataloghi ridotti che potrebbero avere rating artificialmente alti grazie a pochi titoli di successo. Questa vista identifica i publisher con qualità consistente su un portfolio significativo, distinguendo l'eccellenza sistematica dal successo occasionale e permettendo confronti equi tra editori di diverse dimensioni. Il parametro minimo è essenziale per garantire che il rating sia statisticamente rappresentativo della strategia editoriale complessiva.




Figura 7: Dashboard game - sottosezione market(1)




Figura 8: Dashboard game - sottosezione market(2)

6.1.4 Explorer

- Explorer: Top games + drill-down:** Questa vista interattiva combina analisi aggregata e dettaglio individuale attraverso un approccio a due livelli. La sezione superiore permette di filtrare e ordinare i giochi più rilevanti del catalogo utilizzando parametri multipli (Top N, minimo recensioni, età, genere, publisher, modello free-to-play, intervallo temporale), offrendo flessibilità nell'esplorazione del dataset. La tabella risultante presenta metriche chiave per confronto rapido (reviews, avg_sentiment, avg_votes_up, required_age). La sezione drill-down consente di selezionare un singolo gioco e visualizzarne il trend temporale attraverso due grafici sincronizzati: volume di recensioni al giorno (individuazione di picchi di attività) e sentiment medio giornaliero (evoluzione della percezione qualitativa). Questo approccio permette di passare dalla visione macro (quali giochi dominano) alla micro (come si è evoluto nel tempo un titolo specifico), identificando pattern di lancio, aggiornamenti significativi o eventi che hanno impattato la community.

Sezione interattiva per analisi mirate: filtri + selezione gioco + trend temporale.

Top games (filtrati)

Drill-down: trend del gioco selezionato

Selezione gioco

Recensioni al giorno



6.2 Reviews

6.2.1 Overview

La dashboard **Reviews Overview** è focalizzata sull'analisi delle recensioni degli utenti, che rappresentano il fatto centrale del Data Warehouse. Essa consente di studiare sia il volume delle recensioni nel tempo sia il livello di engagement degli utenti.




Figura 10: Dashboard review - overview

6.2.2 distribuzione del rating

- **Distribuzione del rating (review_score dei giochi):** Questo istogramma visualizza quanti giochi hanno ricevuto ciascun punteggio di valutazione (scala 1-9), permettendo di identificare dove si concentra la qualità percepita del catalogo. L'analisi della forma della distribuzione rivela se i rating siano distribuiti simmetricamente, asimmetrici verso valori alti o bassi (skewness), o raggruppati in cluster distinti (multimodalità). Questa vista è

fondamentale per comprendere i pattern aggregati di qualità percepita e per identificare eventuali bias sistematici degli utenti nella valutazione (come tendenza a evitare voti estremi) o effetti di selezione del campione (visibilità differenziale dei prodotti in base alla qualità).




Figura 11: Dashboard review - Distribuzione del rating

6.2.3 Concentrazione delle recensioni

- **Engagement non uniforme: long tail delle recensioni per gioco:** Questa vista documenta la distribuzione asimmetrica dell'engagement attraverso tre componenti complementari. Le metriche di sintesi quantificano il livello di concentrazione dell'attenzione su pochi titoli, mentre la curva rank-recensioni visualizza il fenomeno di power-law (long tail) tipico dei marketplace digitali, mostrando graficamente come l'engagement decresce dal top alla coda della distribuzione. La tabella sottostante identifica i singoli giochi che costituiscono la "testa" della distribuzione. Questa visualizzazione multi-livello permette di analizzare simultaneamente concentrazione aggregata (metriche), pattern distributivo (curva) e composizione specifica (tabella), essenziale per comprendere le dinamiche competitive e le sfide di visibilità nel mercato.




Figura 12: Dashboard review - concentrazione recensioni

6.2.4 Engagement, testo e sentiment

- **Engagement vs Sentiment:** Questa sezione analizza la relazione tra sentiment e metriche di engagement attraverso due coppie di grafici complementari. La prima coppia (numero recensioni per sentiment + votes up medi per sentiment) permette di identificare se esista una correlazione tra polarizzazione delle opinioni e volume/approvazione del feedback, verificando se contenuti estremi generino maggiore risonanza nella community. La seconda coppia (distribuzione lunghezza recensioni + sentiment medio per lunghezza) esplora se l'effort investito nella scrittura influenzi la valutazione espressa, testando l'ipotesi che recensioni più articolate siano qualitativamente diverse da quelle impulsive. Insieme, queste visualizzazioni permettono di mappare le dinamiche comportamentali della community e identificare pattern di engagement selettivo.




Figura 13: Dashboard review - comportamento

7 Conclusioni

Il progetto ha consentito di applicare in modo concreto i principali concetti di *Large Scale Data Management* a un contesto reale caratterizzato da dati eterogenei e di grandi dimensioni, come quello delle recensioni e dei giochi della piattaforma Steam.

Attraverso le diverse fasi di analisi, modellazione e integrazione dei dati, è stato possibile progettare un Data Warehouse basato su un modello multidimensionale coerente con il dominio applicativo e adatto a supportare query analitiche complesse. L'utilizzo di database differenti per la gestione delle sorgenti, unito a una pipeline ETL dedicata, ha permesso di affrontare in modo strutturato problemi tipici dei dataset reali, quali ridondanza, campi non strutturati e volumi elevati di dati.

Le dashboard realizzate rappresentano il livello finale del sistema e consentono di esplorare i dati in maniera interattiva, evidenziando trend, distribuzioni e fenomeni di concentrazione che non sarebbero immediatamente osservabili sui dati grezzi.

Nel complesso, il progetto dimostra come un'adeguata progettazione del modello dei dati e una corretta integrazione delle tecnologie possano facilitare l'analisi di grandi dataset, costituendo una base solida per eventuali estensioni future e approfondimenti analitici.